

Machine learning pour les matériaux

Atelier transformation durable

Astrid Klipfel

Printemps 2026


Faculté des Sciences Jean Perrin

Type de tâches

Classification et régression

Le modèle prédit une propriété physique ou chimique d'un matériau à partir de sa composition ou de sa structure, sans avoir à le synthétiser.

- **Classification** : conducteur/isolant, phase cristalline stable, polymorphe
- **Régression** : band-gap, température de fusion, module d'Young, énergie de formation




- Energie de formation
- band gap
etc.

Ressources : materialsproject.org — [matminer](#)

Segmentation d'images et détection d'objets

Le modèle identifie et délimite automatiquement les structures présentes dans une image de microscopie, sans intervention manuelle.

- **Segmentation** : délimiter grains, phases, précipités (MEB, MET, optique)
- **Détection** : localiser fissures, inclusions, défauts ponctuels



Ressources : U-Net

Optimisation bayésienne

Le modèle apprend des expériences passées et suggère la prochaine condition à tester pour atteindre le meilleur résultat en un minimum d'essais.

- Modèle probabiliste des résultats passés → suggère la prochaine expérience
- Équilibre exploration (zones inconnues) / exploitation (zones prometteuses)

Exemples :

- Optimiser température, pH, temps et concentration pour une synthèse hydrothermale
- Maximiser le rendement catalytique d'un alliage Pt-Pd-X

Experiments - baked >250 cookies



Ressources : Bayesian Optimization


Modèle génératif

Le modèle apprend la distribution des structures connues et peut en proposer de nouvelles qui n'ont jamais été synthétisées.

- VAE, GAN, modèles de diffusion sur des structures connues
- Contrainte forte : stabilité thermodynamique des structures générées

Exemples :

- Nouveaux Metal-Organic Frameworks (MOFs) avec porosité cible
- Cristaux hypothétiques (MatterGen, CDVAE, DiffCSP)



Ressources : CDVAE — MatterGen

Le modèle prédit le mot le plus probable — il ne raisonne pas.

- Extraction de données de synthèse depuis des articles
- Génération de protocoles, résumés, réponses à partir de publications

Limitations à garder en tête :

- **Hallucinations** : produit des résultats faux avec assurance
- **Pas de créativité** : recombine ce qui existe dans ses données
- **Complaisance** : valide les hypothèses de l'utilisateur plutôt qu'il ne les critique

Entraînement et utilisation


Apprendre depuis des données étiquetées :

$$(X, y)_{\text{mesurés}} \rightarrow f : X \mapsto y$$

- Requiert une base de données avec propriétés mesurées
- Plus les données sont nombreuses et variées, meilleur est le modèle

Exemples :

- Prédire la dureté Vickers d'un alliage depuis sa composition (ICSD)
- Prédire l'énergie de formation depuis le calcul DFT (Materials Project)



Ressources : ICSD — oqmd.org — aflow.org —
Materials Project


Modèle génératif

Apprendre la distribution $p(x)$ des données, pas $f(x) \rightarrow y$

- Entraînement non supervisé : pas de label requis
- Le modèle peut ensuite *générer* de nouveaux exemples vraisemblables
- Types : VAE (autoencodeur variationnel), GAN, diffusion

Exemple :

- VAE entraîné sur des zéolithes connues → propose de nouvelles topologies



Ressources : CDVAE — DiffCSP


Fine-tuning

Adapter un modèle à une tâche spécifique

- Entraînement sur des millions de données générales
- Réentraîner sur quelques centaines de données spécifiques
- Avantage : fonctionne avec très peu de données étiquetées

Exemple — GNN pour les matériaux :

- Un **GNN** (Graph Neural Network) représente un matériau comme un graphe
- Pré-entraîné sur des millions de structures DFT, fine-tuné sur quelques centaines de mesures expérimentales



Ressources : MatGL (M3GNet, CHGNet) —


SchNetPack

Intégrer des outils dans un LLM

- **Skill** : prompt d'instructions injecté dans le contexte — dit au LLM *comment* aborder une tâche, sans exécuter de code
- **MCP** (Model Context Protocol) : standard qui connecte un LLM à des outils externes (bases de données, APIs, scripts) pouvant réellement s'exécuter

Exemples :

- Skill « analyse IR » → le LLM suit un protocole d'attribution des bandes
- MCP + Materials Project → le LLM interroge la base et retourne les données réelles




Ressources : [fastMCP](#) — [langchain.com](#)

Évaluer honnêtement les performances du modèle

- Séparer train/test *avant* tout prétraitement
- Attention : des matériaux chimiquement proches dans train et test *faussent* les résultats (*data leakage*)
- Biais fréquent : surreprésentation des oxydes dans les bases ouvertes

Métriques : MAE, RMSE, R^2 (régression); F_1 , AUC-ROC (classification)




Ressources : [matminer \(splits\)](#) — [scikit-learn cross-validation](#)

Sensibilité

Un modèle de classification renvoie un score continu ; le **seuil** choisi détermine le compromis entre faux positifs et faux négatifs.

- **Faux positif (FP)** : le modèle prédit « conducteur » — le matériau est isolant
- **Faux négatif (FN)** : le modèle rate un matériau prometteur — coût élevé en recherche
- Abaisser le seuil → moins de FN, plus de FP (et vice-versa)

La **courbe ROC** trace le taux de vrais positifs vs. le taux de faux positifs pour tous les seuils possibles — l'aire sous la courbe (**AUC**) résume la qualité globale du modèle indépendamment du seuil.



Ressources : `scikit-learn roc_curve` — exemple

ROC

Projets IA/matériaux

Équipe

Les projets IA/matériaux sont par nature interdisciplinaires.

- Info ou maths appliquées pour développer les modèles
- Chimie théorique pour appliquer et interpréter les modèles existants
- Condition clé : volonté d'apprendre du domaine de l'autre

Stratégie de publication

- Tension entre journaux de chimie et journaux d'informatique — à anticiper dès le début
- Définir les objectifs (article méthode vs. article matériau) selon les profils, les données et les moyens

À définir dès le départ : durée du projet, durée d'utilisation prévue, réutilisation, publication open source.

Court terme (quelques mois)

- Scripts ponctuels, skills, MCP
- Vibe coding acceptable
- Pas de maintenance prévue
- Publication possible : notebook ou script documenté

Long terme (> 6 mois)

- Supervision par un-e informaticien-ne
- Documentation avec exemples et instructions d'installation
- Versionnement (Git, DVC) — vérifier le travail des stagiaires, doctorants, post-docs
- Publication d'une librairie open source, valorisation avec des ingénieurs de recherche

Ressources : github.com

À planifier dès le début du projet — pas en fin de thèse.

Données expérimentales

- Formats standards : CSV, JSON, CIF — ne pas inventer de format propriétaire
- Documenter les conditions de mesure pour permettre la réutilisation
- Stocker et versionner : HuggingFace, Figshare, Git + LFS
- Attention aux licences quand vous utilisez des logiciels propriétaires ou des bases de données payantes

Modèles entraînés

- Sauvegarder les poids, hyperparamètres et la version du code
- Documenter les étapes de prétraitement, d'entraînement et d'évaluation
- Viser la reproductibilité complète : quelqu'un d'autre doit pouvoir relancer l'expérience

Ressources : HuggingFace Datasets — figshare.com

Merci

Astrid Klipfel

`astrid.klipfel@univ-artois.fr`

Faculté des Sciences Jean Perrin



[https://research.astrid-klipfel.fr/
talks/transformation_durable.pdf](https://research.astrid-klipfel.fr/talks/transformation_durable.pdf)